네, 발표·보고용으로 쓰실 수 있게 Q&A 형식으로 정리해드릴게요. 실제 결과(조선국왕 사례)를 중심에 두고 흐름을 잡았습니다.

청성조실록 한문 장바구니 분석 — 핵심 Q&A 정리

1. **프로젝트 한 줄 요약**

강희제 실록(1661-1722) 102,861행의 한문 단어 데이터를 NER로 분류한 뒤, FP-Growth 알고리즘으로 **"한문 단어가 같이 등장하는 패턴"**을 추출하는 프로젝트.

핵심 질문: *"이 한문이 나오면 저 한문이 나올 확률이 높다"* 를 정량적으로 찾아낸다.

---

2. **Q1. 왜 NER로 카테고리를 7개나 나눴는가?**

장바구니 분석 알고리즘 자체는 **카테고리를 보지 않는다.** 그냥 "이 단어가 그 달에 등장했는가"만 본다. 그럼에도 카테고리 분류를 한 이유는 세 가지다.

(1) 가장 결정적인 이유 — NONE 필터링

원본 35,154개 단어 중 30,232개(86%)가 NONE이었다. 之, 以, 等, 曰, 海面, 流民 같은 일반어·조사·동사·토크나이저 오류 조각들. 이걸 안 걸러내고 분석을 돌렸으면:

- 之 → 以, 曰 → 之 같은 무의미한 룰이 수만 개 쏟아짐
- 진짜 의미 있는 룰이 노이즈에 묻힘
- support는 높지만 lift는 1 근처로 다 뭉개져 무의미해짐

NER의 진짜 목적은 사실상 **"NONE vs 의미 있는 단어"의 이진 분류**였다.

(2) 결과 해석을 위한 색인

룰을 1,475개 뽑아놓고 전수 검토는 불가능하다. 카테고리 태그(朝鮮國王(PER))가 붙어 있으면:

- "EVT가 들어간 룰만 보자" 같은 선별적 탐색 가능
- 한문 비전공자도 단어 유형을 즉시 파악
- 룰 유형별 분포 메타 분석 가능

(3) 후속 분석 확장성

PER끼리 인물 네트워크, LOC끼리 지명 동시 출현 지도, OFF+LOC로 관직 파견 패턴 등

카테고리별 세분 분석의 기반이 된다.

카테고리 8종: PER(인물), LOC(지명), OFF(관직), GRP(집단), DATE(연호·날짜), SYS(제도), EVT(사건), NONE(기타).

---

3. Q2. 장바구니 분석의 세 지표는 어떻게 해석하는가?

장바구니 분석은 원래 마트 영수증에서 시작됐다. "기저귀 산 사람이 맥주도 사더라" 같은 패턴 찾기. 이 프로젝트에선 **영수증 한 장 = 한 달의 실록 기록**, **상품 = 그 달 등장 한문 단어**다.

룰은 항상 **"A → B"** ("A가 등장한 달엔 B도 등장한다") 형태다.

지표	의미	해석
Support	A와 B가 같이 등장한 달의 비율	0.05 = 758개월 중 약 38개월에 둘이 같이 등장
Confidence	A가 등장한 달 중 B도 등장한 비율	0.9 = A 등장 달의 90%에서 B도 등장
Lift	우연 대비 연관 강도	1.0 = 우연 수준, 10+ = 매우 강한 연관

Lift가 가장 중요하다. Confidence는 B가 원래 흔한 단어면 자동으로 높아지지만, Lift는 우연 효과를 통제한 진짜 연관 강도다.

판단 기준:

- Lift 10+ & Confidence 0.9+ → 거의 확실한 패턴 (정형화된 표현 묶음)
- Lift 3~10 → 의미 있는 경향성 (가설 세우기 좋은 구간)
- Lift 1.5~3 → 약한 연관, 교차 검증 필요
- Lift 1.0 근처 → 무시

비대칭성 활용: A→B와 B→A의 confidence가 다르면, 더 포괄적인 개념 쪽이 confidence가 낮다. 이걸로 어느 쪽이 더 넓은 개념인지 추론할 수 있다.

---

4. Q3. 실제 발견 사례 — 朝鮮國王과 堂子의 결합

발견된 룰

朝鮮國王(PER) → 堂子(LOC), 正月(DATE)

support: 0.071, confidence: 0.982, lift: 13.06

朔(DATE), 朝鮮國王(PER) → 堂子(LOC)

support: 0.071, confidence: 1.000, lift: 12.85

confidence 1.0짜리 룰이 다섯 개나 나왔다. **예외 0건**이라는 뜻.

숫자 해석

- 758개월 중 약 54개월에서 朝鮮國王, 堂子, 正月 셋이 모두 같이 등장
- 朝鮮國王이 등장한 달의 **98.2%**에서 堂子와 正月이 동시 등장
- 우연 대비 **13배** 강한 연관

역사적 해석

- 朝鮮國王 = 조선 국왕 (외교 사안)
- 堂子 = 만주족이 하늘과 조상에게 제사 지내는 신성 장소, **청 황실 만주 정체성의 핵심 상징**
- 正月/元旦/朔 = 모두 정월 초하루

청대 신년 조하(朝賀) 의례의 정형 절차:

5. 황제가 새벽 당자에서 만주식 천제(天祭)
6. 태화전에서 신하들의 조하 수령
7. 친왕·번왕·패륵·대학사 도열
8. **조선을 비롯한 외번 사신의 표문(表文) 진헌**

이 묶음이 강희 통치 62년 동안 거의 예외 없이 반복되어 실록에 기록됐다. 그 정형성이 lift 13.06, confidence 0.98이라는 수치로 잡혔다.

학술적 의의

지난 30년 청사 학계의 가장 큰 논쟁: **청 제국이 한족 왕조의 연속이냐, 만주 정체성을 유지한 내륙 아시아 제국이냐** (New Qing History 논쟁).

이 결과는 New Qing History 입장에 정량적 증거를 제공한다.

조선국왕 의례가 한족식 조공 체제(中華 朝貢)가 아니라 **만주식 천제(堂子)와 묶여 있다**는 것은, 외번 의례가 만주 정체성 의례에 임베드되어 있었다는 가설을 confidence 1.0으로 입증하는 셈이다.

박사과정 몇 년의 사료 정독으로 잡아낼 패턴을, 통계 지표까지 붙여서 추출했다는 점에서 디지털 인문학 방법론의 모범 사례가 된다.

---

9. **Q4. 비지도학습인데 결과가 재활용 가능한가?**

가능하다. 직접 예측 모델로는 못 쓰지만, 다섯 가지 경로로 재활용된다.

(1) 가설 생성 → 지도학습 피처로 투입 (가장 강력)

룰을 **변수(피처)**로 변환해서 예측 모델에 투입할 수 있다.

예: 위기 연도 예측 로지스틱 모델에:

- "의례 의존도" 피처: 朝鮮國王+堂子+正月 룰의 연도별 발동 비율
- "군사 활동" 피처: EVT 관련 룰의 발동 횟수
- "내정 안정" 피처: 정상 작동 룰의 발동 빈도

가설: *"위기가 닥친 해엔 정상적 의례 룰의 발동 빈도가 떨어지고, 비상 룰의 발동이 늘어났을 것이다."*

비지도(룰 추출) → 지도(예측)로 자연스럽게 연결되며, 단순 단어 빈도 모델 대비 성능 비교가 가능하다.

(2) 시계열 분석으로 확장

62년을 통째로 분석한 룰을 시기별로 쪼개 비교:

- 강희 전반기(1661-1684) — 친정 전, 보정대신 시기
- 강희 중반기(1685-1696) — 삼번·대만 평정 후
- 강희 후반기(1697-1722) — 준가르 1차 평정 후

룰의 등장·소멸 패턴 자체가 통치 양상의 변동 지표가 된다.

(3) 다른 사료로 파이프라인 확장

지금 만든 파이프라인 (한문 토크나이징 → NER → 트랜잭션 → FP-Growth)은 **그 자체로 재사용 가능한 자산**이다.

- 옹정조실록(1722-1735): 강희와 의례 패턴이 어떻게 다른가
- 건륭조실록(1735-1796): 십전무공 시대의 군사 EVT 룰 폭발?
- **명실록 vs 청실록 비교**: 같은 신년 조하인데 한족 왕조엔 당자 룰이 안 잡힌다 → New Qing History 논쟁의 결정적 대조 증거
- 조선왕조실록·승정원일기와 교차: 청·조선 사료에서 같은 사건이 어떻게 다르게 묶이는가

(4) 룰 자체를 데이터셋으로 공개

rules_month.csv를 GitHub/Zenodo 등에 공개하면, 다른 청사 연구자가 자기 가설 검증할 때 참조 가능하다. 연구 데이터 인용이 정식 인정받는 추세라 이것도 학술적 재활용이다.

(5) 임베딩과 결합

한문 BERT나 Word2Vec과 결합해 룰의 "의미 일관성 점수"를 산출하면, 1,475개 룰 중 진짜 의미 있는 200개를 자동 선별할 수 있다.

한계도 정직하게

- **직접 예측 불가**: 룰은 기술적(descriptive)이지 예측적(predictive)이 아니다 → (1)번처럼 피처 변환 필요
- **이 데이터셋에 종속**: 강희에서 뽑은 룰은 옹정에 그대로 적용 안 됨 → 모델이 아니라 "방법론과 비교 대상"으로 재활용
- **의미 부여는 사람의 몫**: 알고리즘은 룰을 뽑을 뿐, "외번 의례의 만주식 결합"이라는 해석은 연구자가 한다 (이건 인문학 연구의 본질이라 어쩔 수 없음)

---

10. Q5. 기존 분석(연도별 로지스틱·나이브베이즈)과 어떻게 결합되는가?

두 분석은 **묻는 질문 자체가 다르므로 상호 보완적**이다. 이게 프로젝트의 가장 큰 강점이다.

분석	단위	방법	묻는 질문
기존 연구	**연도별**	로지스틱·나이브베이즈 (지도학습)	"어떤 단어 분포가 위기 연도를 예측하는가?"
본 연구	**월별**	FP-Growth (비지도학습)	"어떤 한문이 같이 등장하는 정형 패턴이 있는가?"

통합 시나리오

가장 강력한 통합 시나리오:

Step 1. 본 연구로 의미 있는 룰 1,475개 추출 (완료)
Step 2. 각 룰의 연도별 발동 빈도를 계산 → 새 피처 생성
Step 3. 기존 로지스틱 모델에 룰 기반 피처 추가
Step 4. "단어 빈도만" vs "단어 빈도 + 룰 피처" 성능 비교

이게 검증되면:

"단어 동시 출현 패턴(연관 규칙)은 단순 빈도보다 통치 위기 신호를 잘 포착한다."

이 결론은 디지털 인문학 논문 한 편 분량이며, **단순 통계가 아니라 상호 검증되는 다층 분석 프레임워크**가 된다.

---

11. Q6. 이 프로젝트의 학술적 위치는?

기존 디지털 인문학 분석과의 차별점

요즘 텍스트 마이닝 연구는 보통 단어 빈도 그래프나 토픽 모델링으로 "이 시기엔 이런 주제가 많았네요" 정도 결론에서 멈춘다. 이 프로젝트는:

1. **구체적 가설**: "조선 의례가 만주 정체성 의례와 결합되었다"
2. **정량적 지표**: lift 13.06, confidence 1.0
3. **사료적 검증 가능성**: 정월 기록 정독으로 직접 확인 가능

세 박자가 다 맞는 점에서 **방법론 자체로 발표 가치 있는 사례**다.

기여 가능 분야

- **청사 연구**: New Qing History 논쟁에 정량적 증거
- **한국사 연구**: 명대 사대 vs 청대 사대의 의례 구조적 차이
- **디지털 인문학**: LLM 기반 NER + 전통적 데이터마이닝 결합 방법론 사례
- **외교사·의례사**: 외번 체제와 황실 의례의 텍스트적 결합 양상

---

12. Q7. 분석 파이프라인 전체 흐름 (재현 가능성)

[원본] 759개 월별 CSV (한자단어, 빈도)

↓ Cell 2: 병합 + 정제 (NaN/허사 제거)

[merged.csv] 102,861행, 35,100 고유 단어

↓ Cell 3-5: DeepSeek NER (8 카테고리)

[ner_results.csv] 4,903 고유 단어 (NONE 제외 21,126행)

↓ Cell 6: 트랜잭션 변환

[transactions_month.csv] 758개월, 평균 28 단어/월

↓ Cell 7: FP-Growth (min_support=0.05, lift≥1.5)

[rules_month.csv] 1,475개 룰

↓ Cell 8: 키워드/카테고리 검색 도구

[해석] 사료 검증 + 가설 생성

기술 스택: Python 3.11, pandas, openai (DeepSeek API), mlxtend (FP-Growth), tqdm

비용: API 호출 1회당 약 0.5달러, 5~6시간 처리.

이렇게 정리해두면 발표·논문 도입부·연구계획서 등에 바로 가져다 쓰실 수 있을 거예요. 특히 **Q3(조선-당자 사례)**와 **Q5(기존 연구와의 통합)**가 청중에게 가장 강한 인상을 줄 부분입니다.

추가로 정리가 필요하거나, 특정 부분을 더 풀어쓰고 싶으시면 말씀하세요.